

Lab1

Lab 1: จำแนกประเภทและออกแบบการจัดเก็บข้อมูล

ให้นักศึกษาสามารถจำแนก Raw Data, Structured, Semi-structured และ Unstructured Data และเลือกวิธีจัดเก็บให้เหมาะสม

โจทย์ มหาวิทยาลัยมีข้อมูลดังต่อไปนี้

1. ตารางข้อมูลนิสิตในไฟล์ CSV
2. ข้อมูลจากเซนเซอร์อุณหภูมิในรูปแบบ JSON
3. ภาพจากกล้องวงจรปิด
4. ไฟล์ PDF ใบสมัครทุน
5. Log การใช้งานระบบ LMS
6. ตารางผลการลงทะเบียนเรียนในฐานข้อมูล MySQL
7. ไฟล์เสียงจากศูนย์รับแจ้งปัญหา
8. ข้อมูลดิบจากเครื่องอ่านบัตรที่ยังไม่ได้ตรวจสอบ

ให้นักศึกษาสร้างตารางวิเคราะห์ โดยระบุ

- ประเภทข้อมูล
- รูปแบบไฟล์หรือ Schema [อธิบาย]
- แหล่งจัดเก็บที่เหมาะสม เช่น Relational Database, Object Storage, Data Lake หรือ Data Warehouse

ข้อมูลจากโจทย์	ประเภทข้อมูล	รูปแบบไฟล์หรือ Schema	แหล่งจัดเก็บที่เหมาะสม
ตารางข้อมูลในไฟล์ CSV	Semi-structured	รูปแบบไฟล์ CSV จัดเก็บเป็นข้อความ (Text) แบ่งคอลัมน์ด้วยเครื่องหมายจุลภาค (Comma) และแบ่งแถวด้วยการขึ้นบรรทัดใหม่ ไม่มี Schema บังคับเข้มงวด	Data Lake หรือ Object Storage
ข้อมูลจากเซนเซอร์อุณหภูมิในรูปแบบ JSON	Semi-structured	รูปแบบไฟล์ JSON เก็บรูปแบบ Key-Value Pairs สามารถมีโครงสร้างซ้อนทับกัน (Nested) ได้ มีความยืดหยุ่นสูง	Data Lake หรือ Object Storage
ภาพจากกล้องวงจรปิด	Unstructured Data	รูปแบบไฟล์วิดีโอ/ภาพ เช่น MP4, AVI หรือ JPEG เป็นข้อมูลพิกเซลที่ไม่มีโครงสร้าง ฟิลต์ให้ Query ได้โดยตรง	Object Storage
ไฟล์ PDF ใบสมัครทุน	Unstructured Data	รูปแบบไฟล์เอกสาร PDF ประกอบด้วยข้อความ รูปภาพ และการจัดหน้ากระดาษ ไม่สามารถดึงข้อมูลเป็นฟิลด์ตารางได้ทันที	Object Storage
Log การใช้งานระบบ LMS	Semi-structured	รูปแบบไฟล์ Log มักเป็น Text File หรือ JSON ที่บันทึกเหตุการณ์ (Event) ตามลำดับเวลา พร้อมข้อมูลเช่น Timestamp, IP Address, Action	Data Lake

ตารางผลการลงทะเบียนเรียนในฐานข้อมูล MySQL	Structured	Relational Schema มีโครงสร้างชัดเจนประกอบด้วย ตาราง (Table), แถว (Row), และคอลัมน์ (Column) มีการกำหนด Data Type และ Relation (Primary Key / Foreign Key)	Relational Database
ไฟล์เสียงจากศูนย์รับแจ้งปัญหา	Unstructured Data	รูปแบบไฟล์เสียง เช่น MP3, WAV เป็นข้อมูลคลื่นเสียงที่ไม่มีฟิลด์ข้อมูลตาราง	Object Storage
ข้อมูลดิบจากเครื่องอ่านบัตรที่ยังไม่ได้ตรวจสอบ	Raw Data	รูปแบบ Binary หรือ Text ดิบ เป็นแพ็คเกจข้อมูลที่เพิ่งรับมาจากฮาร์ดแวร์ ยังไม่มีการจัดรูป	Data Lake