

Lab 2: ทำความสะอาดข้อมูลดิบจากเซนเซอร์ IoT

วัตถุประสงค์

ให้นักศึกษาสามารถตรวจสอบและแก้ไขปัญหา Error, Duplicate, Missing Value และ Outlier ในข้อมูลดิบ

ชุดข้อมูลตัวอย่าง

ในไฟล์ .csv

งานที่ต้องทำ

1. ระบุปัญหาคุณภาพข้อมูลในแต่ละแถว
2. กำหนด Data Quality Rules เช่น
 - อุณหภูมิต้องอยู่ระหว่าง 0–50 องศาเซลเซียส
 - device_id ห้ามเป็นค่าว่าง
 - ห้ามมีข้อมูลซ้ำที่มี device_id และ timestamp เดียวกัน
 - ค่าแบตเตอรี่ต้องอยู่ระหว่าง 0–100
3. เขียนโปรแกรมด้วย Python/Pandas หรือ SQL เพื่อ
 - ลบข้อมูลซ้ำ
 - แปลงค่าผิดปกติเป็น NULL
 - จัดการ Missing Value
 - เพิ่มคอลัมน์ data_quality_status
4. เปรียบเทียบจำนวนแถวก่อนและหลังทำความสะอาด
5. อธิบายว่าทำไมจึงไม่ควรลบ Raw Data ต้นฉบับ

ผลลัพธ์ที่ต้องส่ง

- Source code
- ไฟล์ข้อมูล Cleaned Data
- รายงานปัญหาที่พบ
- ตารางสรุปจำนวน Error, Duplicate, Missing Value และ Outlier

อธิบายว่าทำไมจึงไม่ควรลบ Raw Data ต้นฉบับ

- เพราะว่า หากในอนาคตพบว่าโมเดลประมวลผลผิดพลาด หรือมีวิธีการวิเคราะห์ที่ดีขึ้น เราจะสามารถดึงข้อมูลดิบกลับมาประมวลผลใหม่ได้ หากลบทิ้งไปแล้ว ข้อมูลต้นฉบับจะสูญหายถาวร

ประเภทปัญหา	คอลัมน์ที่พบ	จำนวนที่พบ (เคส)	วิธีการจัดการ
Duplicate	device_id,timestamp	25	ลบแถวที่ซ้ำซ้อนออก (Keep First)
Outlier (Error)	temp_c	15	แปลงเป็น NULL แล้วแทนค่าด้วยค่าเฉลี่ย รายอุปกรณ์
Missing Value	device_id	13	ลบแถวนั้นออกเนื่องจากข าด ID ระบุอุปกรณ์
Error	battery	15	แปลงเป็น NULL